TECNOLÓGICO NACIONAL DE MÉXICO

TECNOLÓGICO NACIONAL DE MÉXIC
INSTITUTO TECNOLÓGICO DE ZACATEPEC

REPORTE TÉCNICO

Inferencia estadística y toma de decisiones en ingeniería

Caso A: Arquitectura de software — Monolito vs. Microservicios

Asignatura	Fundamentos de Ciencia de Datos
Actividad	Actividad Integradora — Evaluación Práctica de la Unidad 2
Integrantes	- Dorantes Solís Mauricio Daniel - Romano Salgado Oscar Roman
Maestra	Campos Hernandez Ana Celia
Fecha	18 de octubre de 2026
Repositorio	github.com/Danields077/Examen-U2

Resumen ejecutivo

Se evaluó si la sobrecarga de red de una arquitectura de microservicios incrementa la latencia de respuesta HTTP respecto a un monolito. Se trabajó con un dataset sintético de 500 observaciones (250 por grupo) generado a partir de distribuciones gamma, el cual quedó en 483 registros (240 monolito, 243 microservicios) tras remover valores atípicos con el criterio 1.5×IQR.

Las medias muestrales resultaron muy cercanas: **123.20 ms** (monolito) y **124.61 ms** (microservicios), con una diferencia de 1.41 ms. El intervalo de confianza al 95 % para la diferencia de medias fue **(−6.80, 9.63) ms**, que contiene al cero. La prueba t de una cola arrojó **t = 0.338** y **p-value = 0.3676** ($> \alpha = 0.05$), por lo que **no se rechaza H_0** : con estos datos no hay evidencia estadística suficiente de que los microservicios aumenten la latencia media.

Esta conclusión no demuestra que ambas arquitecturas sean idénticas; solo indica que, con el tamaño de muestra disponible, cualquier diferencia existente es demasiado pequeña para detectarse (ver sección 6.4).

1. Objetivo y metodología

Objetivo. Aplicar estadística descriptiva, simulación del Teorema Central del Límite (TCL), estimación por intervalos de confianza y pruebas de hipótesis paramétricas para sustentar una decisión técnica sobre la arquitectura de un sistema.

Variables. Variable cuantitativa (Y): latencia de respuesta HTTP en milisegundos. Variable cualitativa (X): tipo de arquitectura (Monolito vs. Microservicios).

Herramientas. Python con numpy, pandas, matplotlib, seaborn y scipy, ejecutado en un cuaderno Jupyter (Google Colab). La semilla aleatoria se fijó en 42 para garantizar reproducibilidad.

Flujo de trabajo. (1) generación del dataset; (2) limpieza y estadística descriptiva; (3) simulación del TCL por remuestreo; (4) intervalos de confianza; (5) prueba de hipótesis y decisión.

2. Dataset

No se dispuso de un conjunto de datos público para este caso, por lo que se empleó **generación sintética justificada**, tal como permite la actividad. La latencia de las peticiones web suele ser positiva y con cola derecha, comportamiento que describe bien una distribución gamma desplazada (el desplazamiento representa la latencia mínima de red). Se generaron 250 observaciones por grupo:

Grupo	Distribución	Parámetros	Media teórica
Monolito	Gamma + desplazamiento	forma = 2.5, escala = 35, desplazamiento = 40	2.5×35 + 40 = 127.5 ms
Microservicios	Gamma + desplazamiento	forma = 2.2, escala = 40, desplazamiento = 45	2.2×40 + 45 = 133.0 ms

Los datos se guardaron en *data/dataset_caso_a.csv* (original, 500 filas) y *data/dataset_caso_a_depurado.csv* (depurado, 483 filas). Cumple el requisito de N ≥ 400 en total y al menos 200 observaciones por grupo antes y después de la limpieza.

Nota de transparencia: como el dataset es simulado, los resultados describen el modelo generador y no el desempeño de un sistema real. Antes de tomar una decisión de producción conviene replicar el análisis con telemetría real (por ejemplo, Locust o Apache Bench).

3. Bloque 1 — Estadística descriptiva y limpieza

3.1 Carga y verificación

El DataFrame tiene 500 filas y 2 columnas: *latencia_ms* (float64) y *grupo* (object). No hay valores ausentes en ninguna columna.

3.2 Detección y remoción de valores atípicos

Se aplicó el criterio del rango intercuartílico por grupo: se conservaron las observaciones dentro de [Q1 − 1.5·IQR, Q3 + 1.5·IQR]. Se eliminaron 17 registros (3.4 %) y ambos grupos conservaron más de 200 observaciones.

Grupo	Antes	Después	Atípicos removidos
Monolito	250	240	10
Microservicios	250	243	7
Total	**500**	**483**	**17**

3.3 Estadísticos descriptivos

Grupo	Media	Mediana	Desv. est. (s)	Varianza (s^2)	Asimetría	Curtosis
Monolito	123.200	117.012	43.529	1,894.787	0.620	−0.137
Microservicios	124.614	113.969	48.204	2,323.634	0.775	−0.071

Unidades en ms (varianza en ms^2). La curtosis es la de Fisher (exceso respecto a la normal).

3.4 Visualización e interpretación

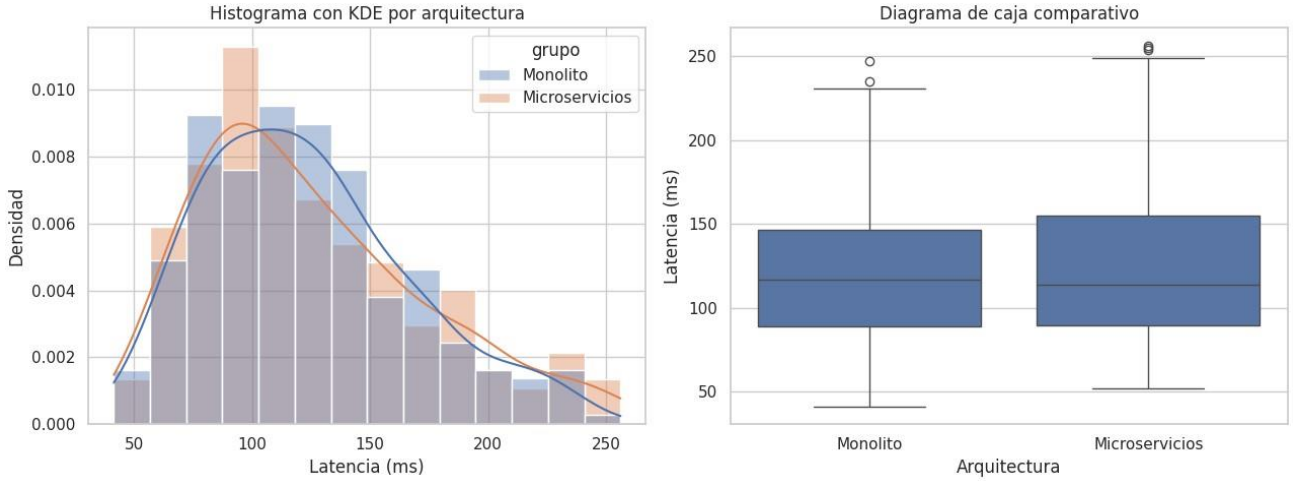


Figura 1. Histogramas con curva KDE (izquierda) y diagramas de caja comparativos (derecha).

Dispersión. Los microservicios muestran mayor variabilidad (s = 48.2 ms frente a 43.5 ms; varianza 23 % mayor), lo cual se aprecia en la caja más ancha. Aun así, ambas cajas se traslapan casi por completo.

Sesgo. Ambas distribuciones presentan asimetría positiva (0.62 y 0.77): la cola derecha es más larga, es decir, pocas peticiones muy lentas elevan la media por encima de la mediana (123.2 vs. 117.0 ms en monolito; 124.6 vs. 114.0 ms en microservicios). La curtosis cercana a cero indica colas de peso similar al de una normal.

Observación. Los diagramas de caja aún muestran algunos puntos por encima del bigote superior porque matplotlib/seaborn recalcula los cuartiles sobre los datos ya depurados; la limpieza se aplicó una sola vez, como indica la actividad.

4. Bloque 2 — Distribuciones de muestreo y Teorema Central del Límite

Se tomó la muestra global depurada (N = 483; media = 123.91 ms; s = 45.90 ms) y se realizó un remuestreo con reemplazo de **k = 1,000** muestras para cada tamaño n ∈ {5, 15, 30, 60}, calculando la media de cada remuestra.

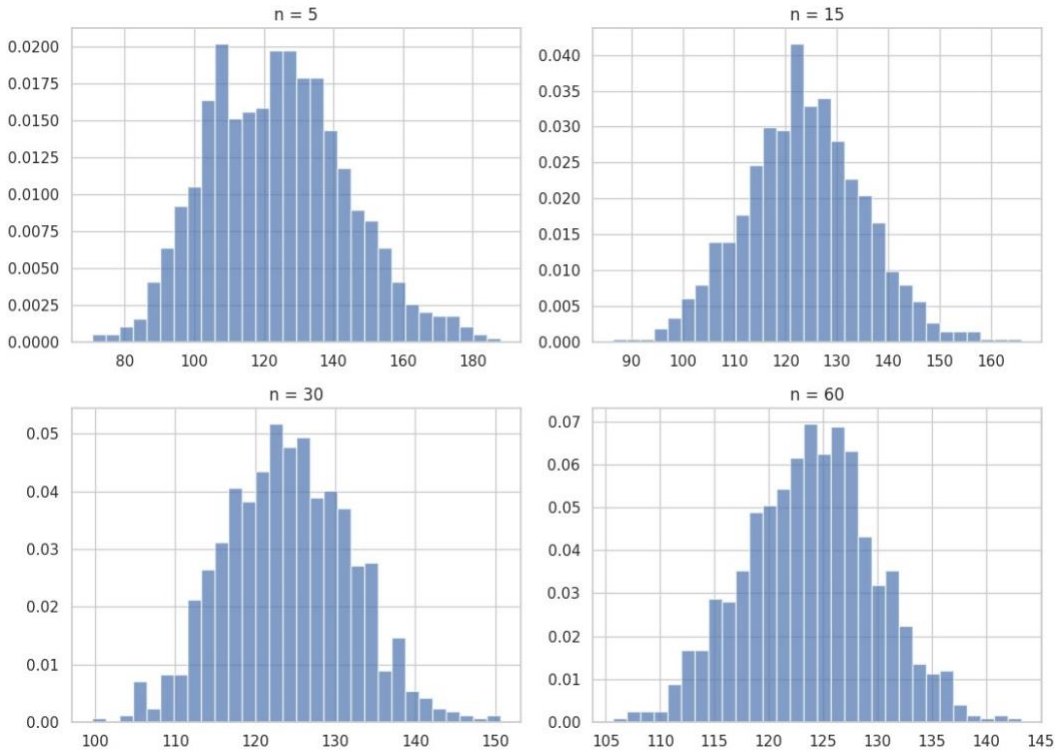


Figura 2. Distribución de las 1,000 medias muestrales para n = 5, 15, 30 y 60.

Se comparó el error estándar empírico (desviación estándar de las 1,000 medias) con el valor teórico $\sigma_{\bar{x}} = s/\sqrt{n}$:

n	EE empírico	EE teórico (s/√n)	Diferencia relativa
5	19.925	20.526	−2.9 %
15	11.597	11.851	−2.1 %
30	7.880	8.380	−6.0 %
60	5.999	5.925	+1.2 %

Interpretación. El error estándar empírico coincide con el teórico en todos los casos (diferencias entre 1 % y 6 %), y ambos disminuyen en proporción a 1/√n: al cuadruplicar n de 15 a 60, el error se reduce aproximadamente a la mitad (11.6 → 6.0). Las diferencias residuales se atribuyen a la variabilidad propia de simular solo 1,000 remuestras.

Convergencia a la normalidad. La población original es asimétrica (asimetría ≈ 0.7). Con n = 5 el histograma de medias conserva una ligera cola derecha; conforme n crece, la distribución se simetriza y adopta la forma de campana. Con n = 30 y n = 60 es prácticamente normal, aun partiendo de una población no normal. Esto es justo lo que establece el TCL y respalda el uso de inferencia basada en la media con las muestras de este estudio (n ≈ 240 por grupo).

5. Bloque 3 — Estimación por intervalos de confianza

5.1 Intervalos para la media poblacional (μ)

Selección de la distribución. La desviación estándar poblacional σ es desconocida y se estima con s, por lo que corresponde la distribución **t de Student** con N − 1 = 482 grados de libertad. Además, la normalidad de los datos no es estrictamente cierta (la prueba de Shapiro-Wilk rechaza normalidad en ambos grupos), pero el TCL con N grande garantiza que la media muestral

se distribuye aproximadamente normal. Con tantos grados de libertad, t y Z son casi idénticas (por ejemplo, t = 1.965 frente a z = 1.960), de modo que la elección no altera la conclusión.

0.975 0.975

Confianza	Límite inferior (ms)	Límite superior (ms)	Amplitud (ms)
90 %	120.47	127.35	6.88
95 %	119.81	128.02	8.21
99 %	118.51	129.31	10.80

Mayor confianza implica un intervalo más ancho: es el costo de tener más seguridad de capturar a μ. Con 95 % de confianza, la latencia media poblacional se ubica entre 119.81 y 128.02 ms.

5.2 Intervalo para la diferencia de medias ($\mu_{micro} - \mu_{mono}$)

Prueba de Levene (homogeneidad de varianzas): estadístico = 1.842, p-value = 0.1754. Como p > 0.05, no se rechaza la igualdad de varianzas, por lo que se utilizó el intervalo con **varianza combinada** (t con n + n − 2 = 481 grados de libertad, t = 1.965).

1 2 crítico

Diferencia de medias	Intervalo de confianza al 95 %	¿Contiene el 0?
1.41 ms	(−6.80, 9.63) ms	Sí

5.3 Interpretación de $0 \in IC$

Como el cero pertenece al intervalo, **no se puede descartar que la diferencia real entre ambas arquitecturas sea nula**. Los datos son compatibles tanto con que los microservicios sean hasta ~9.6 ms más lentos como con que sean hasta ~6.8 ms más rápidos. En términos prácticos, la diferencia observada de 1.41 ms es pequeña frente a una latencia media de ~124 ms (≈1.1 %) y no es estadísticamente distinguible de cero.

6. Bloque 4 — Teoría de decisión (prueba de hipótesis)

6.1 Planteamiento de hipótesis

$H_0 : \mu_{micro} \leq \mu_{mono}$ — los microservicios no aumentan la latencia.

$H_1 : \mu_{micro} > \mu_{mono}$ — los microservicios sí aumentan la latencia (prueba de una cola, a la derecha).

6.2 Matriz de decisión y costo de los errores

Decisión	H verdadera (no aumentan la latencia)	H falsa (sí aumentan la latencia)
Rechazar H_0	**Error Tipo I** (probabilidad $\alpha = 0.05$)	Decisión correcta (potencia = $1 - \beta$)
No rechazar H_0	Decisión correcta (confianza = $1 - \alpha$)	**Error Tipo II** (probabilidad β)

Costo del Error Tipo I (α): concluir que los microservicios son más lentos cuando en realidad no lo son. Se invierte tiempo y dinero en optimizar o rediseñar la arquitectura sin necesidad, o se descarta una migración que sí convenía.

Costo del Error Tipo II (β): ignorar una latencia real. Se despliega en producción una arquitectura más lenta, lo que degrada la experiencia del usuario, puede incumplir los acuerdos de nivel de servicio (SLA) y obliga a rehacer trabajo después.

6.3 Prueba y veredicto

Nivel de significancia α = 0.05. Se aplicó *scipy.stats.ttest_ind* con varianzas iguales (coherente con Levene) y alternativa «greater»:

Estadístico t	Grados de libertad	p-value (una cola)	Nivel α	Decisión
0.338	481	0.3676	0.05	**No rechazar H 0**

Como p = 0.3676 > 0.05 (y t = 0.338 es menor que el valor crítico de ≈ 1.65), **no se rechaza H** .

0

El resultado es coherente con el intervalo de confianza del bloque anterior, que incluye al cero.

6.4 Alcance y limitaciones

No rechazar H no equivale a demostrar que no hay diferencia. Con ~240 observaciones por grupo

0

y s ≈ 46 ms, la diferencia mínima detectable con 80 % de potencia (α = 0.05, una cola) es de aproximadamente 10 ms. Una diferencia real menor que eso podría pasar inadvertida, es decir, existe riesgo de Error Tipo II para efectos pequeños. Además, el análisis compara solo medias; en sistemas web también importan los percentiles altos (p95, p99), donde la cola derecha puede diferir entre arquitecturas.

6.5 Recomendación técnica de ingeniería

- Con la evidencia disponible, **la latencia no es un argumento estadísticamente respaldado en contra de adoptar microservicios**: no se detectó un incremento significativo frente al monolito.
- La decisión de arquitectura debe apoyarse en otros criterios (escalabilidad, despliegue independiente, mantenibilidad, costo operativo), ya que la latencia media no los distingue.
- Antes de producción, validar con pruebas de carga reales (Locust o Apache Bench) y muestras mayores, y comparar también percentiles p95 y p99 y no solo la media.
- Si el SLA tolera diferencias del orden de 10 ms, la conclusión es robusta; si exige diferencias menores, se requiere una muestra mayor para tener potencia suficiente.

7. Conclusiones

- El dataset depurado (N = 483) muestra distribuciones asimétricas a la derecha y medias casi iguales (123.20 vs. 124.61 ms).
- La simulación confirmó el TCL: las medias muestrales tienden a una distribución normal y su error estándar empírico concuerda con s/√n.
- El IC al 95 % para la diferencia de medias, (−6.80, 9.63) ms, contiene al cero.
- La prueba t (t = 0.338, p = 0.3676) no rechaza H a α = 0.05: no hay evidencia de que los

  0

  microservicios incrementen la latencia media.
- Por tratarse de datos simulados, los hallazgos deben confirmarse con mediciones reales antes de una decisión de producción.

8. Estructura del repositorio y reproducibilidad

Repositorio: *https://github.com/Danields077/Examen-U2*

Carpeta	Contenido
data/	dataset_caso_a.csv (original) y dataset_caso_a_depurado.csv (depurado)
notebooks/	Examen.ipynb — cuaderno ejecutable, con semilla fija (42)
docs/	Este reporte en PDF y las figuras generadas

Para reproducir el análisis basta ejecutar el cuaderno de principio a fin; genera los datos, las figuras y todos los resultados de este reporte.

Referencias

- Walpole, R. E., Myers, R. H., Myers, S. L. y Ye, K. *Probabilidad y estadística para ingeniería y ciencias*. Pearson.
- Montgomery, D. C. y Runger, G. C. *Applied Statistics and Probability for Engineers*. Wiley.
- Documentación de SciPy: scipy.stats (ttest_ind, levene, t). https://docs.scipy.org/doc/scipy/reference/stats.html
- Documentación de pandas, NumPy, Matplotlib y seaborn.